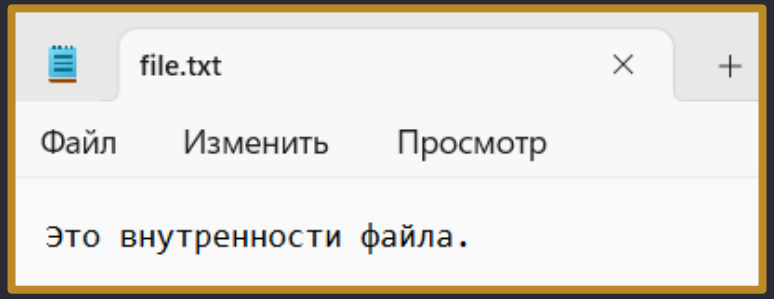
Программирование в лингвистике

Лекция 11

Работа с файлами

Файлы, os, json, pickle, dill

Файлы в Python




```
fin = open("file.txt", "r")
read_text = fin.read()
print(read_text)
fin.close()
```

```
Это внутренности файла.
```

Python работает с файлами через систему.
Для работы с файлами у Python есть дескриптор файла – специальный класс, который позволяет читать данные из файла.

В мире Python изначально существует два типа файлов: текстовые (хранятся в формате .txt, .rtf) и бинарные (хранятся в формате .bin).

Открытие файла

file = open(path, mode, encoding)

> path – абсолютный или относительный путь к файлу.
> mode – режим работы с файлом, str. Может быть ‘r’ – read, ‘w’ – write, ‘rb’ – read bin, ‘wb’ – write bin, ‘r+’ – read & write, ‘rb+’ – read & write bin и др.
> encoding – кодировка файла, str. Часто следует указывать utf8.

Прежде чем начать работать с файлом, следует его открыть.

Функция open() создает объект класса IOWrapper, у которого есть свои методы чтения, записи и закрытия. Path - это путь к файлу, единственный обязательный аргумент.

```
fin = open("file.txt", "r", encoding="utf8")
```

Особенности path

```
open('C:\train\new\text.txt')
```



```
open('C:\\train\\new\\text.txt')
```

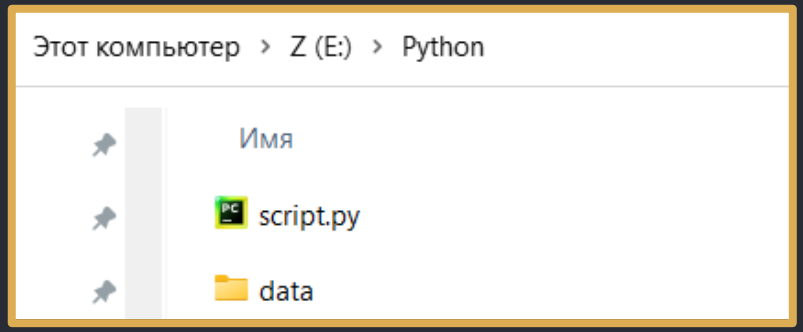


```
open(r'C:\train\new\text.txt')
```



В Windows в путях используется бэкслеш. Пути – строки, поэтому Python будет искать специальные символы вроде \n. Так, можно либо экранировать бэкслэш, либо ставить флаг r.
В Linux и MacOS используется обычный слэш.

Особенности path



Пути бывают абсолютными и относительными. Абсолютный путь включает в себя всё от корня (буквы диска в Windows, папки home в Linux). Относительный – часть пути, если следовать от расположения скрипта Python.

Здесь пути к файлу text.txt, находящемуся в папке data, для кода script.py, будут такими:

```
fin = open(r'E:\Python\data\text.txt')
```

```
fin = open(r'data\text.txt')
```

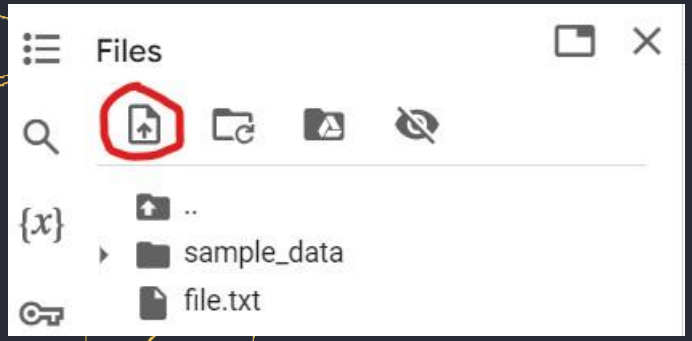
Абсолютный - E:\Python\data\text.txt
Относительный – data\text.txt

Если файл лежит прямо в той директории, где находится скрипт, то достаточно будет open('text.txt').

Открытие файлов в Google Colab



Самый простой способ – использовать вкладку «файлы».



При нажатии на иконку файла открывается файловый менеджер, в котором мы можем выбрать файл из нашего компьютера.

Теперь мы сможем обращаться к этому файлу с помощью относительных путей в Colab.

Режимы open()

Самые распространенные:
'r' – чтение
'w' – запись
'a' – запись с дополнением

```
fin = open("file.txt", "r")
read_text = fin.read()
fin.close()
fout = open("out.txt", "w")
fout.write(read_text)
fout.close()
```

'r' – по умолчанию. Если такого пути не существует, возникнет ошибка.

'w' принимает существующий путь с несуществующим файлом. Если такой файл существует, то он будет перезаписан. Расширение может быть любым, но внутри файл будет текстовым.

Режим **'a'** упрощает запись в существующий файл. Он не будет перезаписан – новые данные добавятся в конец.

Параметр encoding=

```
fin = open('file.txt', 'r')
print(fin.read())
```

```
□7□4□5□A□L□ □1□K□;□8□ □:□@□0□:□>□7□O□1□@□K
```

```
fin = open('file.txt', 'r', encoding='utf-16be')
print(fin.read())
```

```
здесь были кракозябры
```

Рекомендуется всегда указывать кодировку и при чтении, и при записи. Если этого не делать, то есть шанс получить или записать кракозябры.
Лучше всего работать с utf-8.

(Этот файл изначально был записан в кодировке utf-16be, поэтому открывать его нужно точно так же).

Чтение файла

Метод	Пояснение
file.read()	Прочитает файл целиком и вернет его большой строкой, где каждую строчку разделяет \n. Не лучшее решение для огромных файлов.
file.readlines()	Прочитает файл целиком и вернет список строк. В конце каждой строки будет прилеплен \n.
file.readline()	Считывает одну строчку и возвращает строку. В конце строки также будет \n.
for line in file: ……	Считывает по одной строке из файла на каждой итерации, пока не дойдет до конца файла. Лучший способ для огромных файлов.

Запись файла

Метод	**Пояснение**
file.write(**str**)	Записывает строку любого размера в файл. Не ставит \n в ее конце. Возвращает количество записанных символов.
file.writelines(**list**)	Записывает список строк в файл. Тоже не ставит \n в конце каждой строки.
file = open(path, 'w') print(**any**, file=file)	Записывает любой тип данных (в виде строки) в файл (нужно передать в параметр file результат open()). Поддерживает f-строки и другие возможности print.

Закрытие файла

Закрытие файла обязательно:
информация запишется только после закрытия, а сам файл в этом случае наконец исчезнет из оперативной памяти.

```
fout = open('file.txt', 'w', encoding='utf8')
fout.write('some text')
fout.close()
```

Контекстный менеджер

Пожалуй, самый удобный способ работы с файлами. В этом случае нам не нужно помнить о закрытии файла: когда мы уйдем с отступа, файл закроется сам.

```
with open('file.txt', 'w', encoding='utf8') as fout:
    fout.write('some text')
print('Файл записался и закрылся.')
```

Пример

Итерируемся по строкам в файле:

```
with open('file.txt', 'r', encoding='utf8') as fin:
    for line in fin:
      print(line.rstrip())
```

```
три
строки
читаем
в цикле
```

Функции встроенного в os модуля path

Функция	Пояснение
os.path.exists(path)	Проверяет, существует ли такой путь. Возвращает bool.
os.path.isdir(path)	Проверяет, является ли путь папкой.
os.path.isfile(path)	Проверяет, является ли путь файлом.
os.path.isabs(path)	Проверяет, является ли путь абсолютным.
os.path.abspath(path)	Возвращает абсолютный путь по относительному.
os.path.splitext(path)	Делит путь на расширение и все, что ему предшествует. Возвращает кортеж (путь, расширение) – например, (‘E:/data/text’, ‘.txt’).
os.path.split(path)	Делит путь на файл и все, что ему предшествует. Возвращает кортеж (путь, файл) – например, (‘E:/data/’, ‘text.txt’).
os.path.join(path1, path2,….)	Объединяет несколько строк в один путь. Не умеет работать с буквой диска (т.е., не получится правильно объединить 'C:' и 'Python'). Учитывает особенности системы

Обход папки в pathlib

Path.glob('*.txt'), Path.rglob('*.txt'), Path.iterdir() — обход папок

```
from pathlib import Path

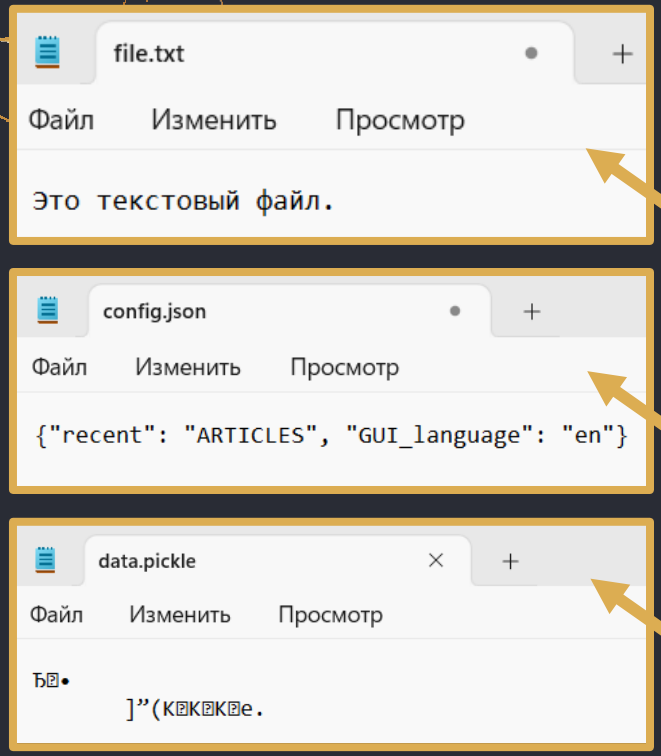
for path in Path('data').glob('*.txt'):
    print(path.name, path.stat().st_size)
```

glob — по маске в одной папке, rglob — рекурсивно по всем вложенным.

```
p = Path('data') / 'text.txt'
p.exists() # True/False
p.is_file() # файл?
p.is_dir() # папка?
p.suffix # '.txt'
p.stem # 'text'
p.parent # Path('data')
p.resolve() # абсолютный путь
```

pathlib удобнее os.path: пути — объекты, а не строки.

Форматы файлов, сериализация



Файлы, которые умеет обрабатывать питон, находятся на своего рода шкале по уровню читаемости человеком:

1. .txt файлы - легко читаются человеком, трудно читаются скриптами (потому что не структурированы).

2. .json, .csv файлы - могут читаться как человеком, так и машиной.

3. бинарные файлы - не предназначены для чтения человеком.

JSON

```
import json

dct = {'a': 1, 'b': 2}
with open('json_file.json', 'w',
          encoding='utf8') as fout:
  json.dump(dct, fout)
with open('json_file.json', 'r',
          encoding='utf8') as fin:
  js = json.load(fin)
type(js)
```

```
dict
```

json - JavaScript Object Notation; первоначально создавался для ЯП JavaScript, но может быть использован и для типов Python.

Это такой формат, в котором объекты Python записываются в машиночитаемом виде, но при этом могут читаться и человеком.

Запись данных в машиночитаемом виде называется сериализацией: когда мы считываем такие файлы снова программой, не нужно их специально парсить.

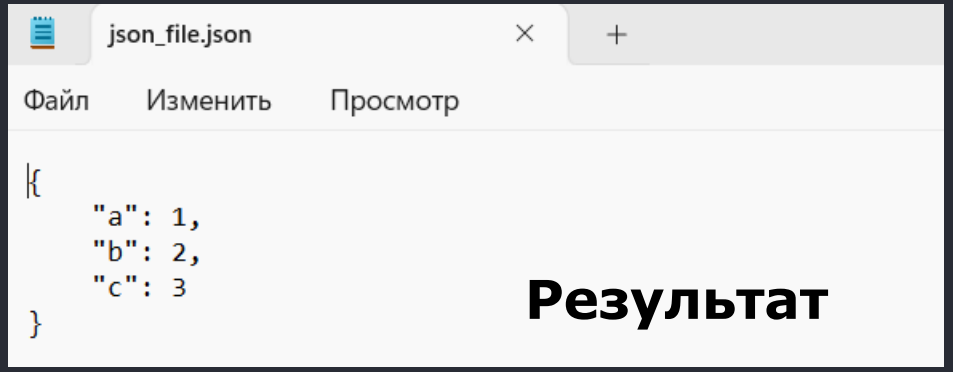
С json-файлами работает встроенный модуль json.

Функции json

Функция	Пояснение
json.load(file)	Принимает файл. Загружает объект в скрипт Python.
json.dump(object, file, ensure_ascii=False, indent=4)	Выгружает объект в файл.
json.loads(string)	Преобразует строку в формате JSON в объект Python.
json.dumps(object)	Преобразует объект в строку Python.

Пример сериализации json

```
with open('json_file.json', 'r', encoding='utf8') as fin:
  dct = json.load(fin)
dct['c'] = 3
with open('json_file.json', 'w', encoding='utf8') as fout:
  json.dump(dct, fout, ensure_ascii=False, indent=4)
```



Результат

Здесь мы десериализуем словарь вида {'a': 1, 'b': 2}, в коде добавляем элемент 'c': 3 и сериализуем его.

Pickle

```
import pickle

lst = [1, 2, 3]
# Выгружаем
with open('list.pickle', 'wb') as fout:
  pickle.dump(lst, fout)

# Загружаем
with open('list.pickle', 'rb') as fin:
  pickled_lst = pickle.load(fin)
pickled_lst
```

```
[1, 2, 3]
```

Быстрее и лучше всего машина читает бинарные файлы, записывать которые умеет встроенный модуль pickle.

Pickle позволяет выгрузить любой объект Python в бинарном виде, а затем в любой момент загрузить его.

Также можно использовать библиотеку dill (ее надо установить pip install dill), у обоих модулей примерно одинаковый синтаксис.

Спасибо за внимание!

Контакты для связи: ajumo@yandex.ru, abyssian03@gmail.com
GitHub: https://github.com/abyssian03/Stud-2